

$$\Pr(\overline{X} - \mu \geq t) \leq e^{-2nt^2}$$

$$\Pr(|S_n| \geq t) \leq 2 \exp\left(-\frac{t^2}{2\sigma^2}\right)$$

@MISatIE | 强化学习理论

机器学习·笔记

第 1 章

第 1.1 节

马尔可夫决策过程

...

理论框架与 Bellman 方程

本章进度：第 1 / 3 节



1.1 马尔可夫决策过程 MDPs

马尔可夫决策过程（MDP）是一种描述序贯决策问题的数学模型：在这样的問題里，环境会随时间演化，而我们每一步做出的动作不仅带来即时奖励，还会影响之后可能遇到的状态和未来的奖励。因此，MDP 提供了一个统一框架来刻画“状态—动作—转移—奖励”的循环过程。

马尔可夫决策过程

- 状态空间 $\mathcal{S}$ （为叙述简便，设为有限或可数）；
- 动作空间 $\mathcal{A}$ （此处假设有限）；
- 转移核 $P(\cdot \mid s, a) \in \Delta(\mathcal{S})$ ；
- 奖励 $r : \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$ （可随机；常用其期望）；
- 折扣因子 $\gamma \in [0, 1)$ ；
- 初始分布 $\mu \in \Delta(\mathcal{S})$ 。

动态过程： $s_0 \sim \mu$ ； $t = 0, 1, 2, \dots$ ，选择 $a_t \sim \pi(\cdot \mid s_t)$ ，获得 $r_t = r(s_t, a_t)$ ，并有 $s_{t+1} \sim P(\cdot \mid s_t, a_t)$ 。

Remark. 有限时域（finite horizon）情形常用 $\{r_h, P_h\}_{h=1}^H$ ；无限时域（infinite horizon）常用统一的 r, P, γ 。两者均可用动态规划刻画。

1.1.1 策略与值函数

定义 1.1.1 (策略 (policy)) . 策略将信息映射为动作：

- 一般随机策略： $\pi : \mathcal{H} \rightarrow \Delta(\mathcal{A})$ ，其中 $\mathcal{H}$ 为有限轨迹集合；
- 马尔可夫随机策略： $\pi : \mathcal{S} \rightarrow \Delta(\mathcal{A})$ ；
- 确定性马尔可夫策略： $\pi : \mathcal{S} \rightarrow \mathcal{A}$ 。




图 1: MDP 基本结构示意图：在状态 s 下选择动作 a ，得到奖励 $r(s, a)$ ，并以概率 $P(\cdot|s, a)$ 转移到下一个状态 s' 。

定义 1.1.2 (值函数). 给定策略 π 与起始状态 $s_0 = s$ ，定义

$$V^\pi(s) := \mathbb{E}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s, \pi\right], \quad Q^\pi(s, a) := \mathbb{E}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s, a_0 = a, \pi\right].$$

Remark. Q 值可理解为“在 s 先固定执行 a ，此后遵循 π 时的长期价值”，因而是“ V 值在一阶动作条件下的细化”。目标是在每个 s 上最大化 $V^\pi(s)$ 。

1.1.2 马尔可夫化与策略评估

引理 1.1.3 (马尔可夫化). 对任意历史依赖策略 π ，存在马尔可夫随机策略 $\tilde{\pi} : \mathcal{S} \rightarrow \Delta(\mathcal{A})$ 使得

$$V^\pi(s) = V^{\tilde{\pi}}(s), \quad \forall s \in \mathcal{S}.$$

证明. 为便于说明，先给出有限时域版本（折扣情形只需把分布加权即可）。对给定历史依赖策略 π ，定义第 h 步的状态-动作占据率

$$d_h^\pi(s, a) := \Pr_\pi(s_h = s, a_h = a), \quad d_h^\pi(s) := \sum_a d_h^\pi(s, a).$$

若 $d_h^\pi(s) = 0$ 则该时刻几乎从不到达 s ，在此处动作分布不影响任何可观测量；若 $d_h^\pi(s) > 0$ ，定义马尔可夫随机策略

$$\tilde{\pi}_h(a | s) := \frac{d_h^\pi(s, a)}{d_h^\pi(s)}.$$

用全概率公式与归纳可证：对所有 h ，有 $d_h^{\tilde{\pi}}(s, a) = d_h^\pi(s, a)$ （先由相同初始分布开始，假设第 h 步两者的 (s, a) 分布一致，则第 $h+1$ 步的 s' 分布一致；再乘以相同的 $\tilde{\pi}_{h+1}(\cdot | s')$ 得到联合也一致）。于是两者对任意可加性函数的期望相同，特别地

$$V_1^\pi(s_1) = \sum_{h=1}^H \sum_{s,a} d_h^\pi(s, a) r_h(s, a) = \sum_{h=1}^H \sum_{s,a} d_h^{\tilde{\pi}}(s, a) r_h(s, a) = V_1^{\tilde{\pi}}(s_1).$$

折扣无限时域下，令折扣占据率

$$d^\pi(s, a) := (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \Pr_{\pi}(s_t = s, a_t = a), \quad d^\pi(s) = \sum_a d^\pi(s, a),$$

同样定义 $\tilde{\pi}(a | s) = d^\pi(s, a)/d^\pi(s)$ （当 $d^\pi(s) = 0$ 任取）。可用与上相同的“占据率不变性”论证得到

$$V^\pi(s_0) = \frac{1}{1 - \gamma} \sum_{s,a} d^\pi(s, a) r(s, a) = V^{\tilde{\pi}}(s_0).$$

两种情形均证毕。 □

有限时域的策略评估(回代) 给定 $\{P_h, r_h, \pi_h\}$ ，置 $V_{H+1}^\pi \equiv 0$ ，并对 $h = H, H-1, \dots, 1$,

$$V_h^\pi(s) = \sum_a \pi_h(a | s) \left(r_h(s, a) + \mathbb{E}_{s' \sim P_h(\cdot | s, a)} V_{h+1}^\pi(s') \right).$$

1.1.3 平稳策略的 Bellman 一致性与矩阵形式

引理 1.1.4 (Bellman 一致性). 若 π 为平稳，则

$$V^\pi(s) = \sum_a \pi(a | s) Q^\pi(s, a), \quad Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim P(\cdot | s, a)} [V^\pi(s')].$$

特别地，若 π 为确定性，则 $V^\pi(s) = Q^\pi(s, \pi(s))$ 。

令 V^π 视作 $|\mathcal{S}|$ 维向量, Q^π, r 视作 $|\mathcal{S}||\mathcal{A}|$ 维向量。定义

$$P_{(s,a),(s',a')}^\pi := P(s' | s, a) \pi(a' | s'),$$

则

$$Q^\pi = r + \gamma P^\pi Q^\pi.$$

引理 1.1.5. 若 π 为平稳, 则 $I - \gamma P^\pi$ 可逆, 且

$$Q^\pi = (I - \gamma P^\pi)^{-1} r.$$

证明. 对任意非零向量 x , 有 $\|P^\pi x\|_\infty \leq \|x\|_\infty$, 故 $\|(I - \gamma P^\pi)x\|_\infty \geq (1 - \gamma)\|x\|_\infty > 0$, 从而 $I - \gamma P^\pi$ 可逆。代回得式。 $\square$

Remark. 在平稳策略情形, 估计 Q^π 等价于估计 P^π 与 r 。实践中常用线性方程/固定点迭代近似求解。

1.1.4 Bellman 最优性与收敛

定义 Bellman 最优算子 $T : \mathbb{R}^{|\mathcal{S}||\mathcal{A}|} \rightarrow \mathbb{R}^{|\mathcal{S}||\mathcal{A}|}$:

$$(TQ)(s, a) := r(s, a) + \gamma \mathbb{E}_{s' \sim P(\cdot | s, a)} \left[\max_{a' \in \mathcal{A}} Q(s', a') \right].$$

定理 1.1.6 (Banach 压缩映射). T 在 $\|\cdot\|_\infty$ 范数下是 γ -收缩: $\|TQ - TQ'\|_\infty \leq \gamma\|Q - Q'\|_\infty$. 因此存在唯一不动点 Q^* 使 $TQ^* = Q^*$; 且从任意 Q_0 出发的值迭代 $Q_{k+1} = TQ_k$ 收敛到 Q^* , 并满足

$$\|Q_k - Q^*\|_\infty \leq \gamma^k \|Q_0 - Q^*\|_\infty.$$

证明. 对任意 (s, a) ,

$$|(TQ - TQ')(s, a)| \leq \gamma \mathbb{E} \left[\left| \max_{a'} Q(s', a') - \max_{a'} Q'(s', a') \right| \right] \leq \gamma \mathbb{E} [\|Q - Q'\|_\infty] = \gamma \|Q - Q'\|_\infty.$$

由 Banach 不动点定理即得唯一性与收敛性。 $\square$

定理 1.1.7 (Bellman 最优性方程与最优策略). 向量 $Q \in \mathbb{R}^{|S||A|}$ 满足

$$Q = TQ$$

当且仅当 $Q = Q^*$ 。并且取任意贪心策略

$$\pi^*(s) \in \arg \max_{a \in A} Q^*(s, a),$$

则 π^* 为最优平稳确定性策略, 且 $V^{\pi^*}(s) = \max_{\pi} V^{\pi}(s)$ 对所有 s 同时成立。

证明. 记 $(TQ)(s, a) = r(s, a) + \gamma \mathbb{E}_{s'|s, a} [\max_{a'} Q(s', a')]$ 。则对任意 (s, a) ,

$$\begin{aligned} |(TQ - TQ')(s, a)| &= \gamma \left| \mathbb{E}_{s'|s, a} [\max_{a'} Q(s', a') - \max_{a'} Q'(s', a')] \right| \\ &\leq \gamma \mathbb{E}_{s'|s, a} \left[\left| \max_{a'} Q(s', a') - \max_{a'} Q'(s', a') \right| \right] \\ &\leq \gamma \mathbb{E}_{s'|s, a} [\|Q - Q'\|_{\infty}] = \gamma \|Q - Q'\|_{\infty}. \end{aligned}$$

对所有 (s, a) 取上确界得 $\|TQ - TQ'\|_{\infty} \leq \gamma \|Q - Q'\|_{\infty}$ 。 $\gamma < 1$, 故 T 为 γ -收缩。由 Banach 不动点定理, 存在唯一 Q^* 使 $TQ^* = Q^*$, 且迭代 $Q_{k+1} = TQ_k$ 以几何速率收敛。 $\square$

Remark. 有限时域下的最优性递推 ($h = H, \dots, 1$) 为

$$V_h^*(s) = \max_a Q_h^*(s, a), \quad Q_h^*(s, a) = r_h(s, a) + \mathbb{E}_{s' \sim P_h(\cdot|s, a)} [V_{h+1}^*(s')],$$

并令 $\pi_h^*(s) \in \arg \max_a Q_h^*(s, a)$ 。与折扣情形一致, 采用向后归纳可得最优策略。

Takeaway

- **MDP 的核心思想**：它结合了“马尔可夫结构”和“动态规划”。
- **Q 值**：可以理解为“先在状态 s 执行动作 a ，然后继续下去”的长期收益，是 V 值的细化版。
- **Bellman 一致性**：在固定策略下， V 和 Q 要满足一组方程；矩阵形式就是 $Q^\pi = (I - \gamma P^\pi)^{-1} r$ 。
- **最优性**：Bellman 算子 T 是一个“压缩映射”，所以它有唯一的不动点 Q^* ，并且 $Q = TQ \iff Q = Q^*$ 。

参考文献

1. Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Cambridge, MA: MIT Press.
2. Szepesvári, C. (2010). *Algorithms for Reinforcement Learning*. San Rafael, CA: Morgan & Claypool.

感谢阅读

本笔记属于《强化学习理论》系列

“With the light of mathematics, may we illuminate the lucid order that lies beneath the world's complexity.”

如果这份笔记对您有所帮助，欢迎在小红书搜索并关注 @MISatLE，也可以分享给身边需要的朋友。您的支持将成为我更新的动力。

本系列还涵盖：

- 马尔可夫决策过程 (MDP)
- 策略评估与策略迭代
- 值迭代与收敛性分析

联系与关注

小红书: @MISatLE

本文档仅供学习与学术交流，未经授权请勿商用或转载。